Semestre: S3 CI
Filière: IATD
Module: Reinforcement learning

جامعة مولاي إسماعيل
UNIVERSITÉ MOULAY ISMAÏL

المدرسة الوطنية العليا للفنون و المهن
ÉCOLE NATIONALE SUPÉRIEURE D'ARTS ET MÉTIERS

Série 1: TD-TP

Exercice 1:

Deux états $\{s_1, s_2\}$, une seule action (politique fixée). Transitions : $P(s_1 \mid s_1) = 0.5$, $P(s_2 \mid s_1) = 0.5$; $P(s_1 \mid s_2) = 0.2$, $P(s_2 \mid s_2) = 0.8$. Récompenses par état (convention $R(s, a, s') = R(s)$) : $R(s_1) = 1$, $R(s_2) = 0$. Discount $\gamma = 0.9$

1. Écrire les équations de Bellman pour $V^\pi(s_1)$ et $V^\pi(s_2)$
2. Résoudre le système linéaire
3. Démarrer en $V_0 \equiv 0$ et faire 3 itérations $V_{k+1} = T^\pi V_k$
4. Calculer $\rho(V_3) = \|T^\pi V_3 - V_3\|_\infty$ et borner $\|V_3 - V^\pi\|_\infty$

Exercice 2:

On considère une grille 2×2 avec terminal $(2, 2)$ de valeur 0 ; actions $\{\uparrow, \downarrow, \leftarrow, \rightarrow\}$ déterministes, *dynamique bornée* (si l'action sortirait, on reste en place). Récompense **par pas** $R = -1$, $\gamma = 0.9$, $V_0 \equiv 0$

1. Faire 2 itérations VI : $V_{k+1} = T^* V_k$, calculer $\rho^*(V_k) = \|T^* V_k - V_k\|_\infty$
2. Extraire la politique gloutonne π issue de V_2 (tie-breaking déterministe)

Exercice 3:

On considère une grille 3×3, terminal $T = (3, 3)$ de valeur 0, dynamique bornée (bump), $R = -1$ par pas, $\gamma = 0.9$, Initialiser $V_0 \equiv 0$

1. Calculer V_1 pour tous les états non terminaux
2. Calculer V_2 et commenter la propagation des valeurs
3. Extraire la politique gloutonne π_2 à partir de V_2

Exercice 4:

On considère une grille 3×3 d'états (i, j), avec **terminal** $G = (1, 3)$ (absorbant) et un **obstacle** en $(2, 2)$ *infranchissable* (la case n'appartient pas à $\mathcal{S}$). Actions $\{\uparrow, \downarrow, \leftarrow, \rightarrow\}$, dynamique *déterministe et bornée* : sortir de la grille ou viser l'obstacle $\implies$ *bump* (on reste en place). Récompenses : **par pas** $R(s, a, s') = -1$, et **bonus terminal** $+10$ quand $s' = G$; ainsi $R(s, a, s') = -1 + 10\mathbb{I}\{s' = G\}$. Facteur d'actualisation $\gamma = 0.9$. On initialise $V_0 \equiv 0$ sur les états non terminaux.

1. Calculez V_1 puis V_2 de *Value Iteration*, $V_{k+1} = T^* V_k$.
2. Déduisez la **politique gloutonne** π_{V_2} (flèches)
3. On considère maintenant que la politique initiale π_0 : "*droite, sinon haut*" (si $\rightarrow$ mène hors-grille ou à l'obstacle, on applique $\uparrow$). (i) Évaluez V^{π_0} *exactement*. (ii) Améliorez π_0 point par point pour obtenir π_1. La politique change-t-elle?

Exercice 5:

TP1 sur le routage optimal et gestion de flotte pour des drones de livraison autonomes
Une entreprise de logistique déploie des drones de livraison autonomes dans un secteur représenté par une grille de 4×3. Le drone doit naviguer depuis différentes zones de livraison pour arriver au pôle central de recharge et de répartition $G = (0, 2)$ tout en minimisant la décharge de la batterie et en évitant les zones de vent fort.
Spécifications du problème:
Espace d'états ($\mathcal{S}$) : Une grille de 4×3 de coordonnées (i, j) où $i \in \{0, 1, 2, 3\}$ (lignes) et $j \in \{0, 1, 2\}$ (colonnes).État terminal : Le pôle central $G = (0, 2)$ est absorbant avec $V(G) = 0$.
Récompenses $R(s, a, s')$: Coût de mouvement standard : -1 par pas. Zone de vent fort en $(2, 1)$ (forte consommation d'énergie): y entrer ou la traverser entraîne une pénalité supplémentaire de -4 (récompense totale de -5). Livraison réussie au pôle G: récompense bonus de $+15$.
Dynamique: Dynamique de grille bornée (si le drone atteint la frontière de la grille ou essaie de voler hors de la carte, il bute et reste dans la même cellule).
Actions ($\mathcal{A}$) : Nord ($\uparrow$), Sud ($\downarrow$), Est ($\rightarrow$), Ouest ($\leftarrow$).Facteur d'actualisation : $\gamma = 0.9$.
Implémentation de l'itération de valeur

1. Écrire une fonction Python step(i, j, a) qui modélise la dynamique de la grille, les frontières, la pénalité de vent en $(2, 1)$ et la récompense terminale en G.
2. Implémenter l'itération de valeur en partant de $V_0 \equiv 0$ avec un seuil de convergence $\theta = 10^{-4}$.
3. Afficher la matrice de valeur optimale finale V^* et extraire la matrice de politique optimale correspondante en utilisant des flèches ASCII ($\uparrow, \downarrow, \leftarrow, \rightarrow$).

Implémentation de l'itération de politique
Initialiser une politique naïve π_0 où le drone essaie toujours de se déplacer vers le Nord ($\uparrow$) quelle que soit sa position.

1. Implémenter l'itération de politique (Évaluation de politique suivie d'une Amélioration de politique) jusqu'à ce que la politique devienne stable ($\pi_{k+1} = \pi_k$).
2. Comparer le nombre d'itérations nécessaires pour atteindre l'optimalité par rapport à l'itération de valeur.

Exercice 6:

TP2: Navigation intelligente d'un robot dans un entrepôt
Un robot d'entrepôt doit transporter un colis depuis sa position de départ jusqu'à une station de livraison. L'entrepôt est représenté par une grille de cellules. Le robot peut se déplacer dans quatre directions : haut, bas, gauche et droite. Cependant, certaines cellules contiennent des obstacles et le robot doit les éviter. Le robot reçoit les récompenses et pénalités suivantes :

- $+10$ lorsqu'il atteint la station de livraison.
- -5 lorsqu'il entre dans une cellule dangereuse.
- -1 pour chaque déplacement normal, afin d'encourager les trajets courts.
- -5 lorsqu'il tente d'entrer dans un obstacle ou de sortir de la grille ; il reste alors dans sa cellule actuelle.

Le robot doit apprendre la meilleure séquence d'actions pour atteindre la station de livraison tout en maximisant la récompense actualisée espérée.
Le robot démarre dans la cellule en haut à gauche $S = (0, 0)$ et doit atteindre la cellule en bas à droite $G = (3, 3)$. - Cellule dangereuse : $(1, 3)$.
- Obstacles : $(1, 1)$ et $(2, 2)$.
- Facteur d'actualisation γ **0,9**

Pour simplifier l'implémentation, on adopte les conventions suivantes:
- L'objectif est un état terminal : une fois atteint, l'épisode se termine.
- Une transition vers l'objectif rapporte $+10$.
- L'entrée dans la cellule dangereuse rapporte -5, et le robot entre bien dans cette cellule.
- Un déplacement normal rapporte -1.
- Une tentative de déplacement dans un obstacle ou hors de la grille rapporte -5, et le robot reste dans sa cellule.
- La valeur de l'objectif est $V(G) = 0$, car l'épisode se termine à cet endroit et la récompense est reçue au moment de l'entrée dans la cellule.

Implémenter l'itération de valeur (Value Iteration)

1. Initialiser la valeur de tous les états à zéro.
2. Mettre à jour la valeur de chaque état à l'aide de l'équation d'optimalité de Bellman.
3. Répéter les mises à jour jusqu'à ce que la variation maximale des valeurs soit inférieure à $\theta = 10^{-6}$.
4. Extraire la politique optimale
5. Afficher la fonction de valeur et l'action optimale dans chaque cellule accessible.

Implémenter l'itération de politique (Policy Iteration)

1. Initialiser une politique aléatoire ou choisir une action initiale pour chaque état.
2. Évaluer la politique courante.
3. Améliorer la politique en choisissant les actions de manière gloutonne (greedy).
4. Répéter les étapes d'évaluation et d'amélioration jusqu'à ce que la politique ne change plus.
5. Afficher la fonction de valeur finale et la politique optimale.

Questions d'analyse

1. Les deux algorithmes trouvent-ils la même politique optimale ?
2. Leurs fonctions de valeur finales sont-elles identiques à la tolérance près ?
3. Que se passe-t-il si le facteur d'actualisation γ passe de **0,9** à **0,5** ?
4. Comment le trajet optimal change-t-il si la pénalité liée au danger passe à -20 ?